

Проект по базам данных
(проект не по грибам, к сожалению)

Автоматизация процессов сортировки книг и персональных предложений пользователям баз библиотеки

Цель: узнать, что читают разные люди, и подготовить данные для рекомендаций

Выполнили проект:
Проджект-менеджер: Сердюк Семён
Зам. проджект-менеджера: Гульятяева Елизавета
Разнорабочий: Прохоров Роман

Проект прошёл путь от идеи к работающей модели

Итоговая цель — понять, что читают разные группы и какие данные нужны для персональных предложений.

01

Предметная область

Описать предметную область и цель рекомендаций.

02

Аудит

Проверить качество исходных таблиц.

03

Нормализация

Нормализовать сущности.

04

Аналитика

Сравнить фонд и выдачи с помощью SQL и Excel.









В ЛЮБОЙ КОМАНДЕ



ЕСТЬ ТАКИЕ ЛЮДИ

Fishki.net

История проекта 📖

1. Грибы 🍄

Хотели делать проект про грибы, но подходящих данных не нашли.



Нет данных про грибы

2. Большая база

Тема: автоматизация сортировки книг. Нашли базу на 140 тысяч записей, оптимально 150–200.



Всё равно берём 140 000

3. Переделка

Почти закончили и поняли, что всё это надо грузить в SQL. За 2–3 дня сделали базу заново.



Переделали всё за 2–3 дня

Откуда данные

234
читателя

139
книг

234
выдачи

8 + 16
библиотек и библиотекарей

Excel-файл из 6 листов, там же словарь полей. Данные учебные, поэтому мы проверяли ещё и качество.



Данные были взяты(не из леса):

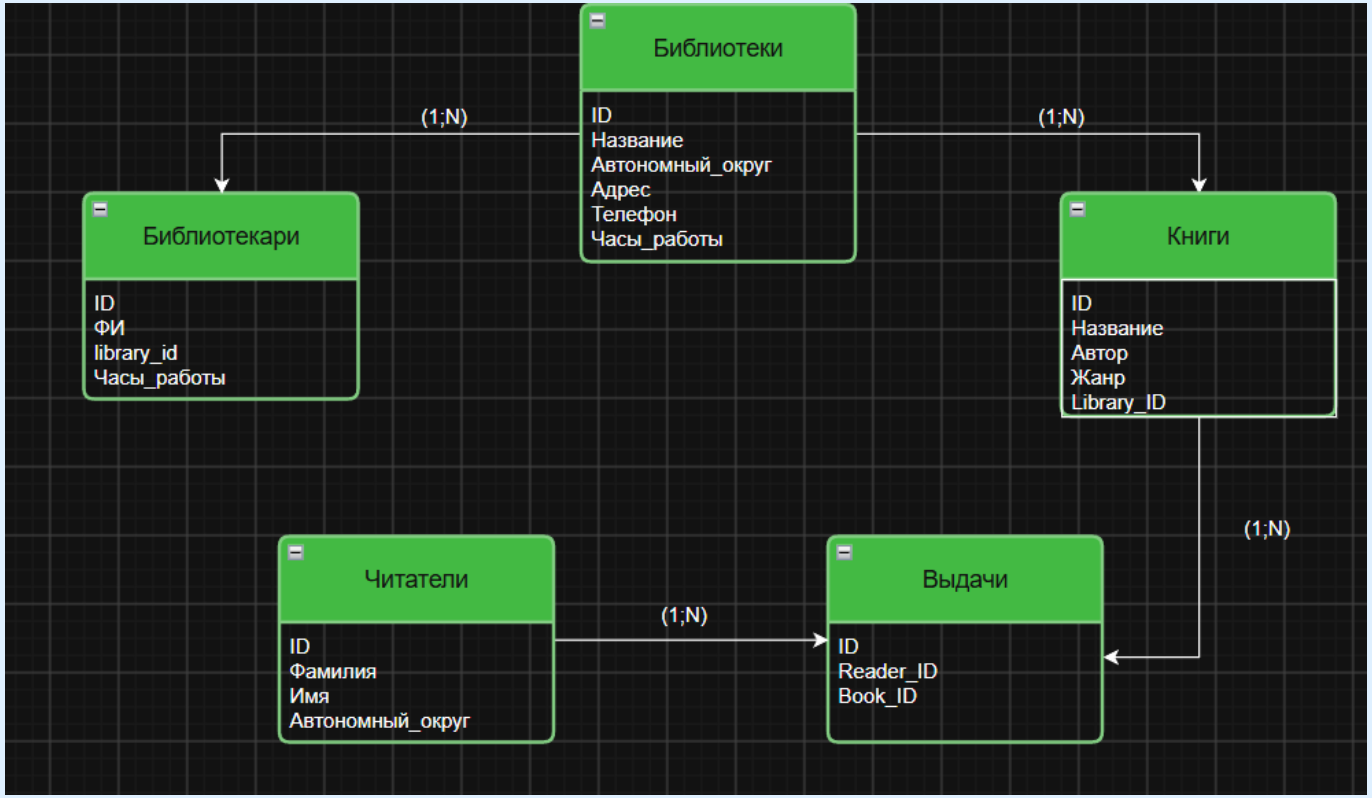
- https://metrics.tilda.ws/surnames -- ФАМИЛИИ
- https://www.kaggle.com/datasets/magdadanina/russian-names-nen/data/data/names.csv?select=names.csv -- имена
- https://ru.wikipedia.org/wiki/Административное_деление_Тюмени -- АО



Что нашли в данных 

- «Калиниский» в библиотеках и «Калининский» у читателей
- Возраст читателей от 6 до 103
- id сделаны формулами, а связи идут по названиям
- Две разные «Сказки» с одним названием
- Один телефон у библиотек № 2 и № 3
- 19 книг ни разу не выдавали

ER-схема и нормализация





Делаем базу и проверяем связи

Что сделали

Загрузили таблицы, добавили ключи, исправили «Калиниский».

Проверка

Все 234 выдачи нашли и читателя, и книгу. Потерянных записей нет ✅

Итог

Можно писать запросы с JOIN.

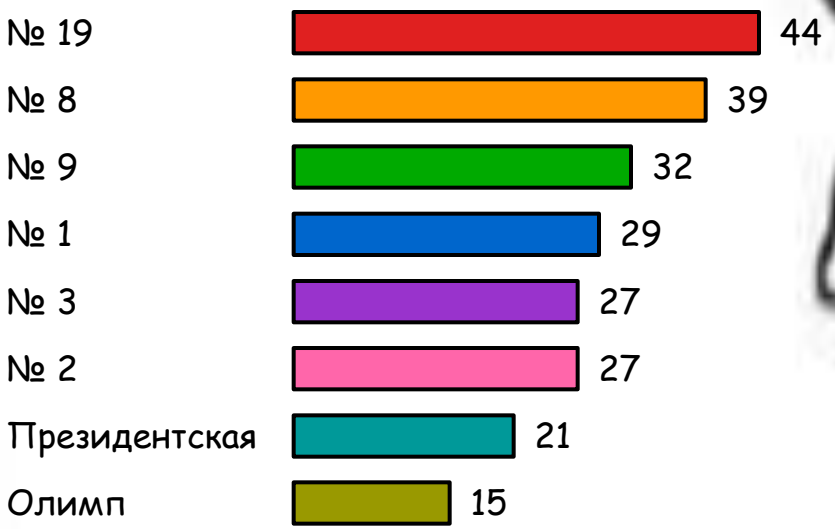


SQL: что интересного

- Жанры: эпическая поэма 15, фантастика 13, исторический роман 12
- Самая популярная книга: «Энеида», 7 выдач
- До 35 лет читают эпос, 36–60 фантастику, 60+ постмодернизм

Вывод: возраст влияет на выбор, значит пригодится для рекомендаций

Excel: выдачи по библиотекам



ОГО, № 19 выдала 44 книги!

Больше всего выдала № 19, меньше всего «Олимп».

Выводы

Что получилось

Данные почистили и связали. Вкусы зависят от возраста и пола.

Минусы

У читателя всего одна выдача, нет дат и оценок. Данных мало, выводы предварительные.

Дальше

Добавить даты, оценки, наличие книг и расстояние до библиотеки.



Мемы проекта 😂



«140 000 золота — это 140 000 данных, которые изначально использовали»

